

บทที่ 3 สถิติข้อมูล (Data Statistics)

วัตถุประสงค์การเรียนรู้

1. อธิบายความหมายและความสำคัญของสถิติสรุป (Summary Statistics) ในกระบวนการสำรวจและวิเคราะห์ข้อมูล
2. จำแนกประเภทของข้อมูลเป็นข้อมูลเชิงหมวดหมู่ (Categorical) และข้อมูลตัวเลข (Numerical) และสำรวจด้วยฟังก์ชัน `value_counts()`, `unique()` และ `nunique()`
3. อธิบายและคำนวณการวัดความถี่และฐานนิยม รวมถึงเปอร์เซ็นต์ไทล์ (Percentile) สำหรับข้อมูลเรียงลำดับได้
4. คำนวณและเปรียบเทียบการวัดแนวโน้มสู่ส่วนกลาง ได้แก่ ค่าเฉลี่ย (Mean) มัชยฐาน (Median) และฐานนิยม (Mode) พร้อมระบุจุดแข็งและข้อจำกัดของแต่ละการวัด
5. คำนวณการวัดการกระจายของข้อมูล ได้แก่ พิสัย (Range) ความแปรปรวน (Variance) ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) และพิสัยระหว่างควอร์ไทล์ (IQR) รวมถึงการวัดแบบทนทานต่อค่าผิดปกติ เช่น AAD และ MAD
6. อธิบายและคำนวณสถิติหลายตัวแปร ได้แก่ ความแปรปรวนร่วม (Covariance) และสหสัมพันธ์ (Correlation) พร้อมทั้งความเมทริกซ์สหสัมพันธ์
7. อธิบายความเบ้ (Skewness) และความสัมพันธ์ระหว่างค่าเฉลี่ย มัชยฐาน และฐานนิยมในการกระจายโมเดลเบ้ขวาและเบ้ซ้าย
8. ใช้ฟังก์ชัน `describe()`, `min()`, `max()`, `median()`, `mode()`, `var()`, `std()`, `quantile()` และ `corr()` ของ Pandas ในการวิเคราะห์ข้อมูลเชิงสถิติ
9. ประยุกต์ใช้การวิเคราะห์เชิงสถิติกับข้อมูลจริง ได้แก่ ข้อมูล Spotify/YouTube และข้อมูลเงินเดือนนักวิทยาศาสตร์ข้อมูล

3.1 บทนำ

การทำความเข้าใจข้อมูลเชิงสถิติ (Data Statistical Understanding) คือกระบวนการได้รับข้อมูลเชิงลึกและความรู้เกี่ยวกับข้อมูลผ่านการวิเคราะห์เชิงสถิติ ขั้นตอนนี้เกี่ยวข้องกับงานต่าง ๆ เช่น สถิติเชิงพรรณนา การกระจายความน่าจะเป็น การทดสอบสมมติฐาน และสถิติอนุมาน เป้าหมายคือการเข้าใจลักษณะของข้อมูล ระบุรูปแบบ และทำนายข้อมูลในอนาคต Python มีแพ็คเกจที่ใช้กันทั่วไปสำหรับการวิเคราะห์เชิงสถิติ ได้แก่:

10. Pandas: มีฟังก์ชันในตัวที่หลากหลายสำหรับคำนวณสถิติสรุปของข้อมูล เช่น ค่าเฉลี่ย มัธยฐาน ส่วนเบี่ยงเบนมาตรฐาน และอื่น ๆ
11. NumPy: มีเครื่องมือสำหรับทำงานกับอาร์เรย์และเมทริกซ์ รวมถึงฟังก์ชันทางคณิตศาสตร์และสถิติที่หลากหลาย
12. SciPy: ต่อยอดจาก NumPy และมีเครื่องมือทางวิทยาศาสตร์และเทคนิคที่หลากหลาย รวมถึงการหาค่าที่เหมาะสม การประมวลผลสัญญาณ และสถิติ
13. statsmodels: มีโมเดลทางสถิติ กระบวนการประมาณค่า และการทดสอบที่หลากหลายสำหรับการวิเคราะห์ข้อมูล

3.2 แนวคิดและทฤษฎีที่เกี่ยวข้อง

3.2.1 ความหมายของสถิติสรุป (Summary Statistics)

สถิติสรุป (Summary Statistics) คือค่าตัวเลขที่ใช้สรุปลักษณะสำคัญของชุดข้อมูลขนาดใหญ่ให้กระชับและเข้าใจง่าย Tan, Steinbach และ Kumar (2006) นิยามว่า สถิติสรุปคือค่าที่บรรยายลักษณะต่างๆ ของชุดข้อมูล เช่น ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน ด้วยตัวเลขเพียงตัวเดียวหรือกลุ่มเล็กๆ ตัวอย่างในชีวิตประจำวัน เช่น รายได้เฉลี่ยครัวเรือน หรือสัดส่วนนักศึกษาที่สำเร็จการศึกษาภายใน 4 ปี ล้วนเป็นสถิติสรุปที่ใช้กันอย่างแพร่หลาย กระบวนการสำรวจข้อมูล (Data Exploration) นั้นอาศัยสถิติสรุปเป็นเครื่องมือหลักในการเข้าใจลักษณะเฉพาะของข้อมูล ช่วยในการเลือกเทคนิคการเตรียมข้อมูลและการวิเคราะห์ที่

เหมาะสม และอาจช่วยตอบคำถามบางส่วนที่เป็นเป้าหมายของการทำการทำเหมืองข้อมูลได้โดยตรง

3.2.2 การวัดความถี่และฐานนิยม

สำหรับข้อมูลเชิงหมวดหมู่ (Categorical Data) การวัดพื้นฐานที่สุดคือความถี่ (Frequency) ซึ่งวัดสัดส่วนของจุดข้อมูลที่มีค่าหนึ่งๆ ในกลุ่มทั้งหมด โดยกำหนดให้ attribute x มีค่าที่เป็นไปได้คือ $\{v_1, \dots, v_v\}$ และมีจุดข้อมูลทั้งหมด m รายการ ความถี่ของค่า v_i นิยามไว้ดังสมการที่ 3.1

$$frequency(v_i) = \frac{n(v_i)}{m} \quad (3.1)$$

ฐานนิยม (Mode) ของ attribute เชิงหมวดหมู่คือค่าที่มีความนิยมนิยมสูงที่สุด สำหรับข้อมูลต่อเนื่อง ฐานนิยมในความหมายดั้งเดิมมักไม่มีประโยชน์มากนัก เนื่องจากค่าแต่ละค่าอาจปรากฏเพียงครั้งเดียว อย่างไรก็ตาม ฐานนิยมอาจบ่งชี้ข้อมูลสำคัญได้ เช่น หากใช้ค่าพิเศษแทนข้อมูลที่ขาดหาย ค่าพิเศษนั้นมักปรากฏเป็นฐานนิยม

3.2.3 เปอร์เซ็นไทล์ ค่าเฉลี่ย และมัธยฐาน

เปอร์เซ็นไทล์ (Percentile) เป็นสถิติที่ใช้กับข้อมูลเรียงลำดับได้ (Ordinal) หรือข้อมูลต่อเนื่อง โดย p -th percentile ของ attribute x คือค่า x_p ซึ่ง $p\%$ ของค่าที่สังเกตได้ทั้งหมดมีค่าน้อยกว่า x_p ตัวอย่างเช่น เปอร์เซ็นไทล์ที่ 50 คือค่า x_{50} ที่มี 50% ของค่าทั้งหมดน้อยกว่าค่านี้ ซึ่งก็คือมัธยฐานนั่นเอง ค่าต่ำสุดและสูงสุดสัมพันธ์กับเปอร์เซ็นไทล์ได้ว่า $\min(x) = x_0\%$ และ $\max(x) = x_{100}\%$

ค่าเฉลี่ย (Mean) เป็นการวัดแนวโน้มสู่ส่วนกลางที่ใช้แพร่หลายที่สุดสำหรับข้อมูลต่อเนื่อง กำหนดให้มีจุดข้อมูล m รายการและค่า attribute คือ $\{x_1, \dots, x_m\}$ ค่าเฉลี่ยนิยามไว้ดังสมการที่ 3.2

$$mean(x) = \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i$$

ข้อสังเกตสำคัญคือ แม้ว่าค่าเฉลี่ยมักถูกตีความว่าเป็นค่ากลางของชุดข้อมูล แต่ความเข้าใจนี้ถูกต้องเฉพาะเมื่อการกระจายตัวของข้อมูลมีลักษณะสมมาตรเท่านั้น หากการกระจายตัวเบ้ (Skewed) มัธยฐานจะเป็นตัวแทนค่ากลางที่ดีกว่า นอกจากนี้ ค่าเฉลี่ยมีความอ่อนไหวต่อค่าผิดปกติ (Outliers) สูง เนื่องจากค่าผิดปกติที่สูงมากหรือต่ำมากจะดึงค่าเฉลี่ยออกจากค่ากลางที่แท้จริง ในกรณีดังกล่าว อาจใช้ Trimmed Mean แทน ซึ่งคำนวณโดยตัดข้อมูล $p/2\%$ จากส่วนบนและล่างออกก่อนจึงค่อยคำนวณค่าเฉลี่ย

มัธยฐาน (Median) คือค่ากลางของชุดข้อมูลเมื่อเรียงลำดับแล้ว กำหนดให้ $\{x_{(1)}, \dots, x_{(m)}\}$ คือค่าที่เรียงลำดับจากน้อยไปมาก มัธยฐานนิยามตามสมการที่ 3.3 ดังนี้ ถ้า m เป็นจำนวนคี่ ($m = 2r+1$) มัธยฐาน $= x_{(r+1)}$ และถ้า m เป็นจำนวนคู่ ($m = 2r$) มัธยฐาน $= \frac{(x_{(r)} + x_{(r+1)})}{2}$ มัธยฐานทนทานต่อค่าผิดปกติดีกว่าค่าเฉลี่ย เนื่องจากขึ้นอยู่กับลำดับของค่าไม่ใช่ขนาดของค่า

3.2.4 การวัดการกระจาย (Measures of Spread)

Kurtosis (Excess)

$$K = \frac{\sum_{i=1}^n (x_i - \bar{x})^4}{n \cdot s^4} - 3$$

โดยที่:

K = ค่า Kurtosis ที่วัดความแหลมหรือความแบนของการแจกแจง

n = จำนวนข้อมูลทั้งหมด

x_i = ค่าข้อมูลลำดับที่ i

$\bar{x}$ = ค่าเฉลี่ยของข้อมูล

s = ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation)

การตีความ: $K = 0$ คือการแจกแจงปกติ (Mesokurtic), $K > 0$ ยอดแหลม (Leptokurtic), $K < 0$ ยอดแบน (Platykurtic)

นอกจากการวัดแนวโน้มส่วนกลางแล้ว การทำความเข้าใจข้อมูลยังต้องการการวัดการกระจายตัว (Spread/Dispersion) เพื่อบอกว่าจุดข้อมูลกระจายออกจากค่ากลางมากน้อยเพียงใด Tan et al. (2006) ได้นำเสนอการวัดการกระจายที่สำคัญไว้ดังนี้

พิสัย (Range) เป็นการวัดการกระจายที่เรียบง่ายที่สุด คำนวณจากผลต่างระหว่างค่าสูงสุดและค่าต่ำสุด: $range(x) = \max(x) - \min(x) = x_{(m)} - x_{(1)}$ แม้จะคำนวณง่าย แต่พิสัยมีจุดอ่อนคือรับอิทธิพลจากค่าผิดปกติเพียงค่าเดียวได้มาก

ความแปรปรวนและส่วนเบี่ยงเบนมาตรฐาน (Variance and Standard Deviation) เป็นการวัดการกระจายที่นิยมใช้มากที่สุด ความแปรปรวน (variance) มักเขียนแทนด้วย s^2x คำนวณตามสมการที่ 3.5 ดังนี้

ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) คือรากที่สองของความแปรปรวน เขียนแทนด้วย sx ข้อดีของส่วนเบี่ยงเบนมาตรฐานคืออยู่ในหน่วยเดียวกับข้อมูลต้นฉบับ ต่างจากความแปรปรวนที่อยู่ในหน่วยยกกำลังสอง เนื่องจากทั้งความแปรปรวนและส่วนเบี่ยงเบนมาตรฐานใช้ค่าเฉลี่ยในการคำนวณ จึงมีความอ่อนไหวต่อค่าผิดปกติสูง โดยเฉพาะความแปรปรวนที่ใช้ผลต่างยกกำลังสอง ทำให้ค่าผิดปกติมีผลอย่างยิ่ง

การวัดการกระจายแบบทนทาน (Robust Measures of Spread) เนื่องจากความอ่อนไหวต่อค่าผิดปกติของความแปรปรวน จึงมีการเสนอการวัดที่ทนทานกว่าสามแบบ ได้แก่ (1) ค่าเบี่ยงเบนสัมบูรณ์เฉลี่ย (Absolute Average Deviation: AAD) $= \frac{1}{m} \sum |x_i - \bar{x}|$ ซึ่งใช้ค่าสัมบูรณ์แทนการยกกำลังสองทำให้ค่าผิดปกติมีอิทธิพลน้อยลง (2) ค่าเบี่ยงเบนสัมบูรณ์มัธยฐาน (Median Absolute Deviation: MAD) $= \text{median}(\{|x_1 - \bar{x}|, \dots, |x_m - \bar{x}|\})$ ซึ่งทนทานต่อค่าผิดปกติยิ่งกว่า AAD และ (3) พิสัยระหว่างควอร์ไทล์ (Interquartile Range: IQR) = ซึ่งวัดการกระจายของ 50% กลางของข้อมูล และใช้เป็นเกณฑ์มาตรฐานในการตรวจหาค่าผิดปกติได้อย่างมีประสิทธิภาพ

3.2.5 สถิติหลายตัวแปร: ความแปรปรวนร่วมและสหสัมพันธ์

เมื่อข้อมูลมีหลาย attributes การวิเคราะห์ไม่ควรจำกัดอยู่แค่แต่ละตัวแปรแยกกัน แต่ต้องพิจารณาความสัมพันธ์ระหว่างตัวแปรด้วย Tan et al. (2006) นำเสนอสถิติหลายตัวแปรที่สำคัญสองประเภท

ความแปรปรวนร่วม (Covariance) วัดระดับที่ตัวแปรสองตัวเปลี่ยนแปลงไปพร้อมกัน โดยค่า s_{ij} ในเมทริกซ์ความแปรปรวนร่วม S คือ $covariance(x_i, x_j)$ ซึ่งคำนวณได้ดังสมการที่

$$3.11: \quad covariance(x_i, x_j) = \frac{1}{m-1} \sum_{k=1}^m (x_i^k - \bar{x}_i)(x_j^k - \bar{x}_j) \text{ โปรดสังเกตว่า}$$

$covariance(x_i, x_i) = variance(x_i)$ ดังนั้นเมทริกซ์ความแปรปรวนร่วมจึงมีความแปรปรวนของแต่ละตัวแปรอยู่ตามแนวแยงหลัก อย่างไรก็ตาม ความแปรปรวนร่วมขึ้นอยู่กับขนาดของตัวแปร จึงไม่สะดวกในการเปรียบเทียบข้ามตัวแปรที่มีหน่วยต่างกัน

สหสัมพันธ์ (Correlation) แก้ปัญหาของความแปรปรวนร่วมด้วยการปรับมาตรฐาน (Normalize) ด้วยส่วนเบี่ยงเบนมาตรฐานของทั้งสองตัวแปร ค่าสหสัมพันธ์ r_{ij} ในเมทริกซ์สหสัมพันธ์ R คำนวณตามสมการที่

$$3.12: \quad r_{ij} = correlation(x_i, x_j) = \frac{covariance(x_i, x_j)}{(s_i \times s_j)} \text{ โดย } s_i \text{ และ } s_j \text{ คือส่วนเบี่ยงเบน}$$

มาตรฐานของ x_i และ x_j ตามลำดับ ค่าสหสัมพันธ์อยู่ในช่วง -1 ถึง 1 เสมอ โดย ค่าใกล้ $+1$ หมายถึงความสัมพันธ์เชิงบวกแข็งแกร่ง ค่าใกล้ -1 หมายถึงความสัมพันธ์เชิงลบแข็งแกร่ง และค่าใกล้ 0 หมายถึงไม่มีความสัมพันธ์เชิงเส้น ค่า diagonal ของเมทริกซ์ R คือ 1 ทุกตำแหน่ง เนื่องจาก $correlation(x_i, x_i) = 1$

สมการที่ 3.12: $r_{ij} = correlation(x_i, x_j) = covariance(x_i, x_j) / (s_i \cdot s_j)$

3.2.6 ความเบ้และการกระจายตัวของข้อมูล

ความเบ้ (Skewness) เป็นสถิติสรุปอีกประเภทหนึ่งที่วัดระดับความสมมาตรของการกระจายตัวของข้อมูลรอบค่าเฉลี่ย ข้อมูลที่มีการกระจายตัวสมมาตรสมบูรณ์แบบจะมีค่าความเบ้เป็น 0 ค่าความเบ้เป็นบวกหมายถึงการกระจายมีหางยาวไปทางขวา (ค่าสูง) และค่าความเบ้เป็นลบหมายถึงหางยาวไปทางซ้าย (ค่าต่ำ) การเข้าใจความเบ้มีความสำคัญในการ

ตีความความสัมพันธ์ระหว่างค่าเฉลี่ย มัธยฐาน และฐานนิยม กล่าวคือ ในการกระจายเบ้ขวา ค่าเฉลี่ย > มัธยฐาน > ฐานนิยม ส่วนการกระจายเบ้ซ้ายจะมีความสัมพันธ์ตรงกันข้าม

นอกจากนี้ยังมีคุณลักษณะของการกระจายที่ไม่สามารถวัดได้ง่ายด้วยตัวเลขเพียงค่าเดียว เช่น ความเป็น Multimodal ซึ่งหมายถึงการกระจายที่มีหลาย “ยอด” (Peaks) แสดงว่า ข้อมูลมาจากหลายกลุ่มย่อย สำหรับกรณีเหล่านี้ Tan et al. (2006) แนะนำให้ใช้วิธีการ แสดงผลด้วยกราฟ เช่น Histogram เพื่อเข้าใจลักษณะการกระจายที่ซับซ้อนกว่านั้น

ตารางที่ 3.1 สรุปสูตรและความหมายของการวัดทางสถิติหลักที่ใช้ในการวิเคราะห์เชิงพรรณนา

การวัด	สูตร / ความหมาย	จุดแข็ง / ข้อจำกัด
Mean (ค่าเฉลี่ย)	$\bar{x} = \frac{1}{m} \sum x_i$	คำนวณง่าย แต่ไวต่อ Outlier
Median (มัธยฐาน)	ค่ากลางหลังเรียงลำดับ = Percentile ที่ 50	ทนทานต่อ Outlier ดีกว่า Mean
Variance (ความแปรปรวน)	$s^2 = \frac{1}{m-1} \sum (x_i - \bar{x})^2$	ไวต่อ Outlier มาก หน่วยเป็นกำลังสอง
IQR	$x_{75\%} - x_{25\%}$	ทนทานต่อ Outlier ใช้ตรวจหา Outlier ได้
Correlation (สหสัมพันธ์)	$r_{ij} = \frac{covariance(x_i, x_j)}{(s_i \times s_j)}$	ค่าอยู่ใน [-1, 1] วัดความสัมพันธ์เชิงเส้น

ที่มา: ปรับปรุงจาก Tan, Steinbach, and Kumar (2006), Introduction to Data Mining, Chapter 3

3.3 การวิเคราะห์ข้อมูลเชิงพรรณนา

เราเริ่มต้นด้วยการตรวจสอบประเภทของข้อมูลอย่างละเอียด โดยแบ่งข้อมูลออกเป็นสองกลุ่มหลัก ได้แก่ ข้อมูลที่ไม่ใช้ตัวเลขและข้อมูลตัวเลข ข้อมูลที่ไม่ใช้ตัวเลขครอบคลุมข้อมูล

เชิงคุณภาพ เช่น หมวดหมู่หรือป้ายกำกับ ส่วนข้อมูลตัวเลขประกอบด้วยค่าเชิงปริมาณ การเข้าใจลักษณะและความสำคัญของประเภทข้อมูลเหล่านี้เป็นสิ่งสำคัญสำหรับการวิเคราะห์ข้อมูลที่มีประสิทธิภาพ

การวัดแนวโน้มสู่ส่วนกลาง (Central Tendency) เป็นพื้นฐานของการวิเคราะห์เชิงสถิติ ได้แก่ ค่าเฉลี่ย (Mean) มัธยฐาน (Median) และฐานนิยม (Mode) ซึ่งให้ข้อมูลเชิงลึกเกี่ยวกับค่ากลาง หรือค่าทั่วไปภายในชุดข้อมูล

นอกจากนี้ยังมีการวัดการกระจาย (Dispersion) เช่น ส่วนเบี่ยงเบนมาตรฐานและความแปรปรวน ซึ่งวัดการแผ่กระจายหรือความแปรปรวนของจุดข้อมูล และพิสัยระหว่างควอร์ไทล์ (IQR) ซึ่งเป็นเครื่องมือที่มีประสิทธิภาพสำหรับระบุค่าผิดปกติและประเมินการกระจายของข้อมูล

3.3.1 แบบฝึกหัด – การทำความเข้าใจเชิงสถิติ

3.3.1.1 การตั้งค่า

```
import pandas as pd
import numpy as np
```

3.3.1.2 โหลดข้อมูล

```
df =
pd.read_csv("/content/Spotify_Youtube_Sample.csv")
df.head()
```

ชุดข้อมูลนี้ประกอบด้วยข้อมูลของ Spotify และ YouTube มีทั้งหมด 20,718 รายการ และ 10 คอลัมน์ ได้แก่ Artist, Track, Album, Album_type (ข้อมูลไม่ใช่ตัวเลข) และ Views, Likes, Comments, Licensed, official_video, Stream (ข้อมูลตัวเลข)

3.3.1.3 ภาพรวมข้อมูล

```
df.info()
df.describe()
```

ฟังก์ชัน describe() ให้สถิติสรุปของคอลัมน์ตัวเลขทั้งหมด ได้แก่ จำนวน ค่าเฉลี่ย ส่วนเบี่ยงเบนมาตรฐาน ค่าต่ำสุด ควอร์ไทล์ที่ 1 (25%), มัธยฐาน (50%), ควอร์ไทล์ที่ 3 (75%) และค่าสูงสุด

3.3.1.4 คุณลักษณะที่ไม่ใช่ตัวเลข

ใช้ฟังก์ชัน value_counts(), unique() และ nunique() เพื่อสำรวจข้อมูลเชิงคุณภาพ:

```
df['Artist'].value_counts() # นับความถี่ของแต่ละศิลปิน
df['Artist'].unique() # แสดงค่าที่ไม่ซ้ำกัน
df['Artist'].nunique() # จำนวนค่าที่ไม่ซ้ำกัน (2,079 ศิลปิน)

nonnumericalcols =
['Artist', 'Track', 'Album', 'Album_type', 'License
d', 'official_video']
df[nonnumericalcols].nunique()
```

3.3.1.5 คุณลักษณะเชิงหมวดหมู่

สร้าง DataFrame แสดงการกระจายของข้อมูลเชิงหมวดหมู่แต่ละคอลัมน์:

```
album_type = pd.DataFrame({'Album_type':
df['Album_type'].value_counts()})
```

ผลลัพธ์: album (14,926), single (5,004), compilation (788)

```
licensed = pd.DataFrame({'Licensed':
df['Licensed'].value_counts()})
```

ผลลัพธ์: True (14,140), False (6,108)

```
official_video =
pd.DataFrame({'official_video':
df['official_video'].value_counts()})
```

ผลลัพธ์: True (15,723), False (4,525)

3.3.1.6 คุณลักษณะเชิงตัวเลข

แบ่งการวิเคราะห์เชิงตัวเลขออกเป็น 3 ส่วนหลัก ได้แก่ แนวโน้มสู่ส่วนกลาง การกระจาย และสหสัมพันธ์

การวัดแนวโน้มสู่ส่วนกลาง (Central Tendency) ได้แก่ ค่าต่ำสุด ค่าสูงสุด มัธยฐาน ฐานนิยม และค่ากึ่งกลาง:

```
col = 'Views'
min = df[col].min()
max = df[col].max()
median = df[col].median()
mode = df[col].mode()[0]
midrange = (max - min) / 2
```

สามารถสร้างฟังก์ชัน getCentralTendency(col) เพื่อคำนวณค่าเหล่านี้สำหรับทุกคอลัมน์ตัวเลข ได้แก่ Views, Likes, Comments และ Stream โดยวนลูปผ่านทุกคอลัมน์:

```
numericalcols = ['Views', 'Likes', 'Comments', 'Stream']
for col in numericalcols:
    getCentralTendency(col)
```

การวัดการกระจาย (Dispersion) ได้แก่ พิสัย ควอร์ไทล์ IQR ความแปรปรวน และส่วนเบี่ยงเบนมาตรฐาน:

```
range = df[col].max() - df[col].min()
quantiles = df[col].quantile([0.25, 0.5, 0.75])
IQR = quantiles[0.75] - quantiles[0.25]
var = df[col].var()
std = df[col].std()
```

ตัวอย่างผลลัพธ์สำหรับคอลัมน์ Views: range = 8,079,649,362, Q1 = 1,826,001.5, Q2 = 14,501,095, Q3 = 70,399,749, IQR = 68,573,747.5, std = 274,644,322

สหสัมพันธ์ (Correlation) แสดงความสัมพันธ์ระหว่างตัวแปรตัวเลข ค่าใกล้ 1 หมายถึงมีความสัมพันธ์เชิงบวกสูง:

```
df[numericalcols].corr()
```

ผลลัพธ์แสดงว่า Views และ Likes มีสหสัมพันธ์สูงมาก (0.891) แสดงว่าวิดีโอที่มียอดชมสูงมักจะมียอดไลก์สูงด้วย ส่วน Comments มีสหสัมพันธ์กับ Views ต่ำกว่า (0.431)

3.3.2 กรณีศึกษา – การวิเคราะห์เชิงสถิติของเงินเดือน Data Science

3.3.2.1 การตั้งค่า

```
import pandas as pd
import numpy as np
```

3.3.2.2 โหลดข้อมูล

```
df = pd.read_csv("/content/ds-salaries.csv")
```

ชุดข้อมูลนี้ประกอบด้วยข้อมูลเงินเดือนในสายงาน Data Science จำนวน 245 รายการ และ 11 คอลัมน์ ได้แก่ work_year, experience_level, employment_type, job_title, salary, salary_currency, salary_in_usd, employee_residence, remote_ratio, company_location และ company_size

3.3.2.3 ภาพรวมข้อมูล

```
df.info()
df.describe()
```

สถิติสรุปของคอลัมน์ตัวเลขสำคัญ: salary_in_usd มีค่าเฉลี่ย 99,868 ดอลลาร์ ค่ามัธยฐาน 81,000 ดอลลาร์ ค่าต่ำสุด 2,876 ดอลลาร์ และค่าสูงสุด 600,000 ดอลลาร์ ส่วน remote_ratio มีค่าเฉลี่ย 69.18% แสดงว่าส่วนใหญ่ทำงานแบบ Remote

3.3.2.4 คุณลักษณะที่ไม่ใช่ตัวเลข

```
df['work_year'].value_counts() # 2021e: 179,
2020: 66
```

```
df['experience_level'].value_counts() # MI: 103,
SE: 77, EN: 54, EX: 11

df['company_location'].value_counts() # US: 108,
DE: 19, IN: 17, GB: 16

df['company_location'].nunique() # 41 ประเทศ

nonnumericalcols =
['work_year', 'experience_level', 'employment_type',
'job_title', 'salary_currency', 'employee_residence',
'company_location', 'company_size']

df[nonnumericalcols].nunique()
```

3.3.2.5 คุณลักษณะเชิงหมวดหมู่

```
employment_type =
pd.DataFrame({'employment_type':
df['employment_type'].value_counts()})
```

ผลลัพธ์: FT (231), PT (7), CT (4), FL (3) — ส่วนใหญ่เป็นงานประจำเต็มเวลา (Full-Time)

```
salary_currency =
pd.DataFrame({'salary_currency':
df['salary_currency'].value_counts()})
```

ผลลัพธ์: USD (126), EUR (57), INR (21), GBP (13), CAD (10) — สกุลเงินที่ใช้มากที่สุดคือ USD

```
company_size = pd.DataFrame({'company_size':
df['company_size'].value_counts()})
```

ผลลัพธ์: L (132), S (58), M (55) — ส่วนใหญ่อยู่ในบริษัทขนาดใหญ่

3.3.2.6 คุณลักษณะเชิงตัวเลข

การวัดแนวโน้มสู่ส่วนกลาง สำหรับคอลัมน์ salary, salary_in_usd และ remote_ratio:

```
numericalcols = ['salary', 'salary_in_usd',
'remote_ratio']

for col in numericalcols:
    getCentralTendency(col)
```

ผลลัพธ์ salary_in_usd: min = 2,876, max = 600,000, median = 81,000, mode = 150,000, midrange = 298,562

การวัดการกระจาย:

```
for col in numericalcols:  
    getDispersion(col)
```

ผลลัพธ์ salary_in_usd: range = 597,124, Q1 = 45,896, Q2 = 81,000, Q3 = 130,000, IQR = 84,104, std = 83,983 — แสดงว่ามีความแปรปรวนของเงินเดือนค่อนข้างสูง

สหสัมพันธ์:

```
df[numericalcols].corr()
```

ผลลัพธ์แสดงว่า salary และ salary_in_usd มีสหสัมพันธ์ติดลบเล็กน้อย (-0.087) ซึ่งอาจเกิดจากอัตราแลกเปลี่ยนสกุลเงิน ส่วน salary_in_usd และ remote_ratio มีสหสัมพันธ์เชิงบวกเล็กน้อย (0.171) แสดงว่าการทำงาน Remote อาจเกี่ยวข้องกับเงินเดือนที่สูงขึ้นเล็กน้อย