

บทที่ 9 รูปแบบที่พบบ่อย (Frequent Patterns)

วัตถุประสงค์การเรียนรู้

1. อธิบายความหมาย หลักการ และแนวคิดพื้นฐานของ Frequent Pattern Mining ได้แก่ Itemset, Support, Confidence, Lift รวมถึงข้อจำกัดของ Support-Confidence Framework และความสัมพันธ์ระหว่าง Frequent, Closed Frequent และ Maximal Frequent Itemset
2. ค้นหา Frequent Itemset ด้วยอัลกอริทึม Apriori โดยใช้แพ็คเกจ mlxtend กำหนดค่า min_support ที่เหมาะสม และแปลงข้อมูล Transaction เป็นรูปแบบ One-Hot Encoded ด้วย TransactionEncoder
3. สร้าง Association Rules พร้อมคำนวณและตีความค่า Support, Confidence และ Lift เพื่อระบุความสัมพันธ์เชิงบวกและเชิงลบระหว่างรายการสินค้า
4. ประยุกต์ใช้อัลกอริทึม FP-Growth เพื่อค้นหา Frequent Itemset โดยอาศัยโครงสร้าง FP-Tree ที่บีบอัดข้อมูลและสแกนฐานข้อมูลเพียง 2 ครั้ง พร้อมอธิบายหลักการ Anti-Monotone Property และ Apriori Principle
5. เปรียบเทียบประสิทธิภาพของ Apriori และ FP-Growth บนชุดข้อมูลเดียวกัน โดยวิเคราะห์ข้อดีและข้อเสียด้านจำนวนการสแกนฐานข้อมูล การสร้าง Candidate Itemset และการใช้หน่วยความจำ
6. ดำเนินการ Market Basket Analysis บนชุดข้อมูล Online Retail จริง ตั้งแต่การโหลดและเตรียมข้อมูล การค้นหา Frequent Itemset ไปจนถึงการสร้างและตีความ Association Rules เพื่อประยุกต์ใช้ในเชิงธุรกิจ

9.1 บทนำ

Frequent Pattern Mining เป็นงาน Data Mining ที่มุ่งค้นพบรูปแบบหรือความสัมพันธ์ในชุดข้อมูลที่เกิดขึ้นบ่อย รูปแบบเหล่านี้สามารถนำไปใช้ค้นพบความสัมพันธ์ระหว่างรายการในชุดข้อมูล และประยุกต์ใช้งานต่างๆ เช่น Market Basket Analysis, Recommendation System และการตรวจจับการทุจริต

วิธีการ Frequent Pattern ที่นิยมใช้ใน mlxtend มีดังนี้:

- Apriori: อัลกอริทึมที่สร้าง Frequent Itemset โดยวนซ้ำกำจัด Itemset ที่ไม่ผ่านเกณฑ์ Minimum Support
- FP-Growth: อัลกอริทึมที่สร้าง Frequent Itemset โดยสร้างโครงสร้างข้อมูลแบบกะทัดรัดที่เรียกว่า Frequent-Pattern Tree ซึ่งช่วยให้สร้าง Frequent Itemset ได้อย่างมีประสิทธิภาพ

9.2 Frequent Itemset และ Association Rules

Frequent Itemset Mining และการวิเคราะห์ Association Rule เป็นเทคนิคพื้นฐานใน Data Mining ที่ใช้ค้นพบความสัมพันธ์และรูปแบบภายในชุดข้อมูลแบบ Transaction ส่วนนี้แนะนำ Frequent Itemset และ Association Rule โดยใช้แพ็คเกจ mlxtend ซึ่งเป็นไลบรารีโอเนกประสงค์สำหรับการวิเคราะห์ Association

Frequent Itemset Mining ระบุชุดของรายการที่มักเกิดร่วมกันใน Transaction ในขณะที่การวิเคราะห์ Association Rule เปิดเผยความสัมพันธ์และการพึ่งพาที่มีความหมายระหว่างรายการต่างๆ เทคนิคเหล่านี้ให้ข้อมูลเชิงลึกที่มีคุณค่าเกี่ยวกับพฤติกรรมลูกค้า การแนะนำสินค้า และอื่น ๆ

9.2.1 ทฤษฎี Frequent Pattern Mining

Leverage

$$L(A \rightarrow B) = \text{supp}(A \cup B) - \text{supp}(A) \cdot \text{supp}(B)$$

โดยที่:

$L(A \rightarrow B)$ = Leverage ของกฎ $A \rightarrow B$

$\text{supp}(X)$ = Support ของ Itemset X (สัดส่วนธุรกรรมที่มี X)

ความหมาย: Leverage วัดว่า A และ B

เกิดร่วมกันมากกว่าที่ควรจะเป็นหากเป็นอิสระต่อกันหรือไม่

การตีความ: $L > 0$ แสดงความสัมพันธ์เชิงบวก, $L = 0$ เป็นอิสระต่อกัน, $L < 0$

แสดงความสัมพันธ์เชิงลบ

Conviction

$$\text{Conv}(A \rightarrow B) = \frac{1 - \text{supp}(B)}{1 - \text{conf}(A \rightarrow B)}$$

โดยที่:

$\text{Conv}(A \rightarrow B)$ = Conviction ของกฎ $A \rightarrow B$

$\text{supp}(B)$ = Support ของ B

$\text{conf}(A \rightarrow B)$ = Confidence ของกฎ $A \rightarrow B$

Conviction วัดความเชื่อในกฎโดยเปรียบเทียบกับกรณีที่ A และ B เป็นอิสระต่อกัน

การตีความ: $\text{Conv} = 1$ แสดงความเป็นอิสระ, $\text{Conv} \rightarrow \infty$ แสดงกฎที่แข็งแกร่งมาก,

$\text{Conv} < 1$ แสดงกฎที่ขัดแย้ง

Frequent Pattern Mining เป็นงาน Data Mining ที่มุ่งค้นพบรูปแบบ ความสัมพันธ์ หรือโครงสร้างที่เกิดขึ้นบ่อยในชุดข้อมูลขนาดใหญ่ Tan et al. (2006) อธิบายว่า Association Analysis หรือ Frequent Pattern Mining เป็นหนึ่งในงาน Data Mining

ที่ได้รับความนิยมสูงสุด โดยมีเป้าหมายเพื่อค้นพบกฎความสัมพันธ์ (Association Rules) ที่แสดงถึงการเกิดร่วมกันบ่อยๆ ของรายการในชุดข้อมูลแบบ Transaction

แนวคิดพื้นฐาน: Itemset และ Support

Tan et al. (2006) นิยาม Itemset ว่าเป็นเซตของรายการ (Items) จาก Transaction Database โดยที่ $I = \{i_1, i_2, \dots, i_d\}$ คือเซตของรายการทั้งหมด และ $T = \{t_1, t_2, \dots, t_N\}$ คือเซตของ Transaction ทั้งหมด Itemset K ที่มีสมาชิก k รายการเรียกว่า k -itemset ค่า Support ของ Itemset K นิยามเป็นสัดส่วนของ Transaction ที่มี K อยู่ด้วย:

$$T(K) = \frac{|\{t_i \mid K \subseteq t_i\}|}{N} \quad \text{Hastie et al. (2009) อธิบายว่า Support}$$

คือการประมาณค่าความน่าจะเป็นร่วม $\Pr(A \text{ และ } B)$ ของรายการที่ปรากฏพร้อมกันในตะกร้าสินค้าที่สุ่มเลือก

Association Rules: Confidence และ Lift

กฎความสัมพันธ์ (Association Rule) มีรูปแบบ $A \Rightarrow B$ โดยที่ A เรียกว่า Antecedent และ B เรียกว่า Consequent Hastie et al. (2009) นิยามตัววัดคุณภาพของ Association Rule ไว้สามตัว ได้แก่ (1) Support: $T(A \Rightarrow B) =$ สัดส่วน Transaction ที่มีทั้ง A และ B

$$(2) \text{ Confidence: } C(A \Rightarrow B) = \frac{T(A \Rightarrow B)}{T(A)} \text{ ซึ่งเป็นการประมาณค่า } \Pr(B|A)$$

หรือความน่าจะเป็นแบบมีเงื่อนไขว่าเมื่อมี A แล้วจะมี B ด้วย (3) Lift:

$$L(A \Rightarrow B) = \frac{C(A \Rightarrow B)}{T(B)} \text{ ซึ่งเป็นการประมาณ } \Pr(A \text{ และ } B) / [\Pr(A) \times \Pr(B)] \text{ ค่า Lift >}$$

1 แสดงว่า A และ B มีความสัมพันธ์เชิงบวก Lift = 1 แสดงว่าเป็นอิสระต่อกัน และ Lift < 1 แสดงว่ามีความสัมพันธ์เชิงลบ

Minimum Support และ Minimum Confidence

Tan et al. (2006) อธิบายว่าการ Mine Association Rules ทำในสองขั้นตอน ขั้นแรกค้นหา Frequent Itemset ทั้งหมดที่มี Support ไม่ต่ำกว่าค่า Minimum Support (`min_support`) ที่กำหนด จากนั้นสร้าง Association Rules จาก Frequent Itemset ที่ได้ โดยเลือกเฉพาะ Rule ที่มี Confidence ไม่ต่ำกว่าค่า Minimum Confidence (`min_confidence`) Hastie et al. (2009) เน้นว่าการกำหนดค่า `min_support` ที่เหมาะสมเป็นสิ่งสำคัญ เนื่องจากจำนวน Frequent Itemset และ Rule จะเพิ่มขึ้นอย่างมากเมื่อลดค่า `min_support`

ข้อจำกัดของ Support-Confidence Framework

Tan et al. (2006) ชี้ให้เห็นว่า Support-Confidence Framework มีข้อจำกัด กล่าวคือ ค่า Confidence อาจทำให้เข้าใจผิดได้ในบางกรณี ตัวอย่างเช่น ถ้ารายการ B มี Support สูงมากอยู่แล้ว Rule $A \Rightarrow B$ อาจมี Confidence สูงโดยไม่ได้สะท้อนความสัมพันธ์ที่แท้จริง นี่คือเหตุผลที่ต้องใช้ Lift ประกอบการพิจารณา นอกจากนี้ Rule ที่มี Lift สูงและ Confidence สูง แต่มี Support ต่ำ (เช่น กฎ วอดก้า $\Rightarrow$ คาเวียร์) จะถูกตัดออกจากการวิเคราะห์ ซึ่งเป็นข้อเสียอีกประการของการใช้เกณฑ์ `min_support`

9.2.2 แบบฝึกหัด – ค้นหา Frequent Itemset

ต่อไปนี้เป็นบทเรียนทีละขั้นตอนสำหรับการรู้จัก Frequent Itemset ตาม Minimum Support โดยใช้อัลกอริทึม Apriori ใน Python

9.2.2.1 การตั้งค่า

ก่อนดำเนินการ ติดตั้งไลบรารี `mlxtend` ซึ่งมี Apriori algorithm ที่มีประสิทธิภาพ:

```
!pip install mlxtend
```

9.2.2.2 โหลดและเตรียมชุดข้อมูล

ใช้ชุดข้อมูลตัวอย่างที่แทน Transaction (เช่น การซื้อในร้านค้า) โดยแต่ละ Transaction แสดงเป็นรายการของสินค้า:

```
import pandas as pd
from mlxtend.preprocessing import TransactionEncoder

# ชุดข้อมูลตัวอย่าง (รายการ Transaction)
dataset = [
    ['Milk', 'Bread', 'Eggs'],
    ['Bread', 'Eggs', 'Butter'],
    ['Milk', 'Eggs'],
    ['Milk', 'Bread', 'Eggs', 'Butter'],
    ['Milk', 'Bread'],
    ['Bread', 'Eggs'],
    ['Milk', 'Bread', 'Butter'],
]

# แปลงชุดข้อมูลเป็นรูปแบบ One-Hot Encoded
te = TransactionEncoder()
te_ary = te.fit(dataset).transform(dataset)
df = pd.DataFrame(te_ary, columns=te.columns_)
print(df)
```

ผลลัพธ์: DataFrame ที่แสดง True/False สำหรับแต่ละสินค้าในแต่ละ Transaction จำนวน 7 รายการ

9.2.2.3 ค้นหา Frequent Itemset ด้วย Apriori

ใช้ Apriori algorithm เพื่อ Mine Frequent Itemset จากชุดข้อมูลที่เข้ารหัสแบบ One-Hot ตาม Minimum Support:

```
from mlxtend.frequent_patterns import apriori
```

```
min_support = 0.4
frequent_itemsets = apriori(df,
min_support=min_support, use_colnames=True)
print(frequent_itemsets)
```

ผลลัพธ์ Frequent Itemsets (support >= 0.4):

```
support itemsets
0 0.857143 (Bread)
1 0.428571 (Butter)
2 0.714286 (Eggs)
3 0.714286 (Milk)
4 0.428571 (Butter, Bread)
5 0.571429 (Eggs, Bread)
6 0.571429 (Milk, Bread)
7 0.428571 (Eggs, Milk)
```

9.2.2.4 วิเคราะห์และตีความผลลัพธ์

ผลลัพธ์คือ DataFrame ที่มี Frequent Itemset พร้อมค่า Support และความยาวของแต่ละ Itemset ค่า Support แสดงสัดส่วนของ Transaction ที่มี Itemset นั้นปรากฏอยู่

จากผลลัพธ์พบว่า Bread มี Support สูงสุด (0.857) หมายความว่าปรากฏใน 6 ใน 7 Transaction ส่วน Itemset คู่ที่พบบ่อยได้แก่ (Milk, Bread) และ (Eggs, Bread) ที่มี Support = 0.571 ข้อมูลเหล่านี้สามารถนำไปสร้าง Association Rule ได้

Frequent Itemset Mining
เป็นเทคนิคที่มีประสิทธิภาพสำหรับระบุความสัมพันธ์ที่น่าสนใจระหว่างรายการในข้อมูล Transaction และสามารถประยุกต์ใช้ในหลายสาขา เช่น Market Basket Analysis, การวิเคราะห์พฤติกรรมลูกค้า และ Recommendation System

9.2.3 แบบฝึกหัด – ค้นหา Association Rules

ในบทเรียนนี้ จะสร้างชุดข้อมูลจำลอง ใช้ Apriori algorithm ค้นหา Frequent Itemset และแสดงค่า Support, Confidence, Lift และเมตริก Association Rule อื่นๆ

9.2.3.1 การตั้งค่า

```
!pip install mlxtend
```

9.2.3.2 สร้างและเตรียมชุดข้อมูลจำลอง

ใช้ชุดข้อมูลเดิมจากหัวข้อ 9.2.2 แปลงเป็น One-Hot Encoded DataFrame

```
import pandas as pd
from mlxtend.preprocessing import TransactionEncoder

dataset = [
    ['Milk', 'Bread', 'Eggs'],
    ['Bread', 'Eggs', 'Butter'],
    ['Milk', 'Eggs'],
    ['Milk', 'Bread', 'Eggs', 'Butter'],
    ['Milk', 'Bread'],
    ['Bread', 'Eggs'],
    ['Milk', 'Bread', 'Butter'],
]

te = TransactionEncoder()
te_ary = te.fit(dataset).transform(dataset)
df = pd.DataFrame(te_ary, columns=te.columns_)
```

9.2.3.3 ค้นหา Frequent Itemset ด้วย Apriori

```
from mlxtend.frequent_patterns import apriori,
association_rules

min_support = 0.4
```

```
frequent_itemsets = apriori(df,
min_support=min_support, use_colnames=True)
print('Frequent Itemsets:')
print(frequent_itemsets)
```

9.2.3.4 สร้าง Association Rules

ใช้ Frequent Itemset สร้าง Association Rules และคำนวณเมตริกต่างๆ เช่น Confidence และ Lift:

```
min_confidence = 0.6
association_rules_df =
association_rules(frequent_itemsets,
    metric='confidence',
    min_threshold=min_confidence)

print('Association Rules:')
print(association_rules_df[['antecedents',
    'consequents',
    'support', 'confidence', 'lift']])
```

ผลลัพธ์ Association Rules (confidence $\geq$ 0.6):

	antecedents	consequents	support	confidence	lift
0	(Butter)	(Bread)	0.428571	1.000000	1.1667
1	(Eggs)	(Bread)	0.571429	0.800000	0.9333
2	(Bread)	(Eggs)	0.571429	0.666667	0.9333
3	(Milk)	(Bread)	0.571429	0.800000	0.9333
4	(Bread)	(Milk)	0.571429	0.666667	0.9333
5	(Eggs)	(Milk)	0.428571	0.600000	0.8400
6	(Milk)	(Eggs)	0.428571	0.600000	0.8400

9.2.3.5 ดีความผลลัพธ์

ผลลัพธ์คือ DataFrame ที่มี Association Rules พร้อมค่า Support, Confidence, Lift และเมตริกอื่นๆ ดีความได้ว่า:

- Rule (Butter) $\rightarrow$ (Bread): Confidence = 1.0 หมายความว่าทุก Transaction ที่มี Butter จะมี Bread เสมอ, Lift = 1.167 แสดงความสัมพันธ์ที่เป็นบวก
- Rule (Milk) $\rightarrow$ (Bread): Confidence = 0.8 หมายความว่า 80% ของ Transaction ที่มี Milk จะมี Bread ด้วย
- ค่า Lift > 1 แสดงว่ารายการเกิดร่วมกันบ่อยกว่าที่คาดโดยบังเอิญ ซึ่งแสดงถึงความสัมพันธ์ที่แท้จริง

Apriori algorithm เป็นเทคนิคที่มีประสิทธิภาพสำหรับค้นหา Frequent Itemset และสร้าง Association Rules ใช้กันอย่างแพร่หลายในการวิเคราะห์ Market Basket และ Recommendation System สามารถปรับ min_support และ min_confidence เพื่อค้นหา Rule ที่มากขึ้นหรือน้อยลงตามความต้องการ

9.3 อัลกอริทึม Apriori และ FP-Growth

Apriori และ FP-Growth เป็นอัลกอริทึมคลาสสิกที่ใช้ในการ Mine Frequent Itemset และวิเคราะห์ Association Rule ส่วนนี้แนะนำอัลกอริทึมทั้งสองที่มีอิทธิพลนี้โดยใช้แพ็คเกจ mlxtend

Apriori และ FP-Growth เป็นอัลกอริทึมสำคัญสำหรับค้นพบ Frequent Itemset และสร้าง Association Rules จากข้อมูล Transaction มีบทบาทสำคัญในการทำความเข้าใจพฤติกรรมลูกค้า การแนะนำสินค้า และการวิเคราะห์ Market Basket

9.3.1 ทฤษฎี อัลกอริทึม Apriori และ FP-Growth

อัลกอริทึม Apriori และ FP-Growth เป็นสองวิธีหลักสำหรับค้นหา Frequent Itemset อย่างมีประสิทธิภาพ ซึ่งเป็นปัญหาที่ท้าทายเนื่องจากจำนวน Candidate Itemset ที่เป็นไปได้มีถึง 2^d ชุดสำหรับข้อมูลที่มี d รายการ

Apriori Algorithm: หลักการและกระบวนการทำงาน

Tan et al. (2006) อธิบายว่า Apriori เป็นอัลกอริทึมแรกที่ใช้ Support-Based Pruning เพื่อควบคุมการเติบโตแบบเอ็กซ์โพเนนเชียลของ Candidate Itemset หลักการสำคัญเรียกว่า Apriori Principle ซึ่งกล่าวว่า: ถ้า Itemset ใดๆ มีความถี่ต่ำ (Infrequent) แล้ว Superset ทุกอันของ Itemset นั้นจะต้องมีความถี่ต่ำด้วย กล่าวอีกนัยหนึ่ง $L \subseteq K \Rightarrow T(L) \geq T(K)$ คุณสมบัตินี้เรียกว่า Anti-Monotone Property ซึ่งช่วยตัด Candidate Itemset ที่ไม่จำเป็นออกได้จำนวนมาก

Apriori ทำงานแบบวนซ้ำ (Iterative) หรือ Level-Wise Search โดย Hastie et al. (2009) สรุปขั้นตอนดังนี้: (1) Pass แรก: นับ Support ของทุก 1-Itemset แล้วตัด Item ที่มี Support ต่ำกว่า min_support ออก (2) Pass ที่สอง: สร้าง Candidate 2-Itemset จากคู่ของ Frequent 1-Itemset นับ Support แล้วตัดที่ไม่ผ่านเกณฑ์ออก (3) Pass ต่อไป: ทำซ้ำสำหรับ Itemset ขนาด 3, 4, ... จนกว่าจะไม่มี Candidate Itemset ใหม่ที่ผ่านเกณฑ์ Apriori ต้องสแกนฐานข้อมูลหนึ่งครั้งต่อขนาดของ Itemset ซึ่งอาจเป็นข้อเสียสำหรับฐานข้อมูลขนาดใหญ่

FP-Growth Algorithm: FP-Tree Structure

Tan et al. (2006) อธิบายว่า FP-Growth (Frequent Pattern Growth) พัฒนาขึ้นมาเพื่อแก้ไขข้อเสียของ Apriori โดยหลีกเลี่ยงการสร้าง Candidate Itemset และสแกนฐานข้อมูลซ้ำๆ FP-Growth ทำงานโดยสร้างโครงสร้างข้อมูลที่เรียกว่า FP-Tree (Frequent-Pattern Tree) ซึ่งบีบอัด Transaction Database ลงในโครงสร้างต้นไม้ที่กะทัดรัด โดยการสแกนฐานข้อมูลเพียง 2 ครั้งเท่านั้น

ขั้นตอนการสร้าง FP-Tree: (1) สแกนฐานข้อมูลครั้งแรกเพื่อนับ Support ของทุก 1-Itemset และตัด Item ที่ไม่ผ่าน min_support ออก (2) เรียง Item ที่เหลือในแต่ละ Transaction ตามลำดับ Support จากมากไปน้อย (3) สแกนฐานข้อมูลครั้งที่สองเพื่อสร้าง FP-Tree โดยแต่ละ Transaction จะถูกแมปเป็นเส้นทางในต้นไม้ Transaction ที่มี Prefix เหมือนกันจะแชร์ Node เดียวกัน ทำให้ประหยัดหน่วยความจำ แต่ละ Node เก็บชื่อ Item และ Count นอกจากนี้ยังมี Header Table ที่เชื่อม Node ของ Item เดียวกันทั้งหมดด้วย Pointer

FP-Growth: การค้นหา Frequent Itemset

Tan et al. (2006) อธิบายว่า FP-Growth ค้นหา Frequent Itemset จาก FP-Tree แบบ Bottom-Up โดยเริ่มจาก Item ที่มี Support น้อยที่สุด สำหรับแต่ละ Item ที่ต้องการ FP-Growth สกัด Conditional Pattern Base ซึ่งเป็นเส้นทางทั้งหมดที่นำไปสู่ Node ของ Item นั้นในต้นไม้ จากนั้นสร้าง Conditional FP-Tree จาก Conditional Pattern Base แล้วค้นหา Frequent Itemset แบบ Recursive จาก Conditional FP-Tree กระบวนการนี้ดำเนินต่อไปจนกว่า Conditional FP-Tree จะว่างเปล่า

การเปรียบเทียบ Apriori และ FP-Growth

Tan et al. (2006) สรุปความแตกต่างสำคัญระหว่างสองอัลกอริทึม: Apriori ต้องสแกนฐานข้อมูลหลายครั้ง (จำนวนเท่ากับขนาดของ Frequent Itemset ที่ใหญ่ที่สุด) และสร้าง Candidate Itemset จำนวนมาก ทำให้ช้ากว่าสำหรับข้อมูลหนาแน่น (Dense Data) หรือ min_support ต่ำ ในทางกลับกัน FP-Growth สแกนฐานข้อมูลเพียง 2 ครั้ง ไม่สร้าง Candidate Itemset ทำให้มีประสิทธิภาพสูงกว่า โดยเฉพาะสำหรับข้อมูลขนาดใหญ่และมี min_support ต่ำ อย่างไรก็ตาม FP-Tree ต้องการหน่วยความจำในการจัดเก็บโครงสร้าง ซึ่งอาจเป็นข้อจำกัดสำหรับข้อมูลขนาดใหญ่มาก

9.3.2 แบบฝึกหัด – อัลกอริทึม Apriori

ทดลองบทเรียน Association Rule Mining โดยใช้อัลกอริทึม Apriori กับชุดข้อมูลจำลองที่แสดง Transaction ในร้านขายของชำ

9.3.2.1 การตั้งค่า

ติดตั้งไลบรารี mlxtend ซึ่งมีการนำ Apriori algorithm มาใช้อย่างมีประสิทธิภาพ:

```
!pip install mlxtend
```

9.3.2.2 สร้างชุดข้อมูลจำลอง

สร้างชุดข้อมูลจำลอง 1,000 Transaction ในร้านขายของชำ แต่ละ Transaction มีสินค้าที่สุ่มเลือกจาก 10 รายการ:

```
import pandas as pd
import numpy as np
from mlxtend.preprocessing import TransactionEncoder

np.random.seed(42)
num_records = 1000
num_items = 10

transactions = []
for _ in range(num_records):
    num_items_in_transaction = np.random.randint(1, num_items + 1)
    items = np.random.choice(range(1, num_items + 1),
                              num_items_in_transaction, replace=False)
    transactions.append([f'Item{item}' for item in items])

te = TransactionEncoder()
```

```
te_ary = te.fit(transactions).transform(transactions)
df_encoded = pd.DataFrame(te_ary,
                           columns=te.columns_)
print(df_encoded)
```

ผลลัพธ์: DataFrame 1,000 แถว × 10 คอลัมน์ (Item1–Item10) แสดงว่าแต่ละ Transaction มีสินค้าใดบ้าง

9.3.2.3 ค้นหา Frequent Itemset ด้วย Apriori

```
from mlxtend.frequent_patterns import apriori

min_support = 0.35
frequent_itemsets = apriori(df_encoded,
                             min_support=min_support, use_colnames=True)
print('Frequent Itemsets:')
print(frequent_itemsets)
```

ผลลัพธ์: พบ Frequent Itemset ทั้งหมด 34 ชุด ประกอบด้วย Itemset เดี่ยว 10 ชุด (Item1–Item10 ล้วนมี Support ~ 0.53–0.55) และ Itemset คู่ 24 ชุดที่มี Support >= 0.35

9.3.2.4 สร้าง Association Rules

ใช้ Frequent Itemset สร้าง Association Rules และคำนวณเมตริก Confidence, Lift และ Support:

```
from mlxtend.frequent_patterns import
association_rules

min_confidence = 0.67
association_rules_df =
association_rules(frequent_itemsets,
```

```
metric='confidence',  
min_threshold=min_confidence)  
print('Association Rules:')  
print(association_rules_df)
```

ผลลัพธ์ Association Rules (confidence ≥ 0.67):

	antecedents	consequents	confidence	lift
0	(Item1)	(Item5)	0.675472	1.2509
1	(Item4)	(Item3)	0.671727	1.2325
2	(Item5)	(Item3)	0.670370	1.2300
3	(Item7)	(Item3)	0.676692	1.2416
4	(Item8)	(Item3)	0.679174	1.2462
5	(Item4)	(Item5)	0.679317	1.2580

สรุป: Item3 ปรากฏเป็น Consequent บ่อยครั้ง แสดงว่ามีความสัมพันธ์กับ Item หลายรายการ ค่า Lift > 1 ทุก Rule แสดงความสัมพันธ์เชิงบวก

9.3.2.5 สรุปทฤษฎีก่อน FP-Growth

ก่อนศึกษา FP-Growth ขอสรุปแนวคิดเพิ่มเติมเกี่ยวกับการแทนรูปแบบ Frequent Itemset อย่างกะทัดรัด

Maximal และ Closed Frequent Itemsets

Tan et al. (2006) นิยาม Maximal Frequent Itemset ว่าเป็น Frequent Itemset ที่ไม่มี Superset ใดที่เป็น Frequent Itemset อีก และนิยาม Closed Frequent Itemset ว่าเป็น Frequent Itemset ที่ไม่มี Superset ใดที่มี Support เท่ากันหรือมากกว่า Closed Frequent Itemset มีความสำคัญในเชิงปฏิบัติเพราะสามารถใช้แทนชุด Frequent Itemset ทั้งหมดได้โดยไม่สูญเสียข้อมูล Support ซึ่งช่วยลดจำนวน Rule ที่ซ้ำซ้อนและไม่มีประโยชน์

ความสัมพันธ์ระหว่าง Frequent, Closed Frequent, และ Maximal Frequent Itemsets: Maximal Frequent $\subseteq$ Closed Frequent $\subseteq$ Frequent Itemsets ทุก Maximal Frequent Itemset เป็น Closed Frequent Itemset แต่ไม่ใช่ทุก Closed Frequent Itemset จะเป็น Maximal ตัวอย่างเช่น ถ้า {a, b, c, d, e} เป็น Frequent Itemset แต่ Superset ทั้งหมดของมันไม่เป็น Frequent แล้ว {a, b, c, d, e} เป็น Maximal Frequent Itemset

9.3.3 แบบฝึกหัด – อัลกอริทึม FP-Growth

บทเรียนนี้แสดง Association Rule Mining โดยใช้อัลกอริทึม FP-Growth กับชุดข้อมูลจำลอง โดยสร้าง Frequent-Pattern Tree แทนการสแกนฐานข้อมูลซ้ำๆ ทำให้มีประสิทธิภาพสูงกว่า Apriori

9.3.3.1 การตั้งค่า

Import ไลบรารีที่จำเป็น:

```
!pip install mlxtend

import pandas as pd
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import fpgrowth, association_rules
```

9.3.3.2 เตรียมชุดข้อมูล

สร้างชุดข้อมูลจำลองเดิมและแปลงเป็นรูปแบบ One-Hot Encoded:

```
dataset = [
    ['Milk', 'Bread', 'Eggs'],
    ['Bread', 'Eggs', 'Butter'],
    ['Milk', 'Eggs'],
    ['Milk', 'Bread', 'Eggs', 'Butter'],
    ['Milk', 'Bread'],
```

```
['Bread', 'Eggs'],  
['Milk', 'Bread', 'Butter'],  
]
```

```
te = TransactionEncoder()  
te_ary = te.fit(dataset).transform(dataset)  
df = pd.DataFrame(te_ary, columns=te.columns_)
```

9.3.3.3 ใช้ FP-Growth ค้นหา Frequent Itemset

```
frequent_itemsets = fpgrowth(df,  
min_support=0.4, use_colnames=True)  
print(frequent_itemsets)
```

ผลลัพธ์ FP-Growth Frequent Itemsets:

```
support itemsets  
0 0.857143 (Bread)  
1 0.714286 (Milk)  
2 0.714286 (Eggs)  
3 0.428571 (Butter)  
4 0.571429 (Milk, Bread)  
5 0.571429 (Eggs, Bread)  
6 0.428571 (Eggs, Milk)  
7 0.428571 (Butter, Bread)
```

สังเกตว่าผลลัพธ์เหมือนกับ Apriori แต่ลำดับของ Itemset อาจต่างกัน เนื่องจาก FP-Growth ใช้การสำรวจต้นไม้แทนการสแกนฐานข้อมูล

9.3.3.4 Mine Association Rules จาก Frequent Itemset

```
min_confidence = 0.6  
association_rules_df =  
association_rules(frequent_itemsets,
```

```
metric='confidence',
min_threshold=min_confidence)

print('Association Rules:')
print(association_rules_df[['antecedents',
'consequents',
'support', 'confidence', 'lift']])
```

ผลลัพธ์ Association Rules จาก FP-Growth:

	antecedents	consequents	support	confidence	lift
0	(Milk)	(Bread)	0.571429	0.800000	0.9333
1	(Bread)	(Milk)	0.571429	0.666667	0.9333
2	(Eggs)	(Bread)	0.571429	0.800000	0.9333
3	(Bread)	(Eggs)	0.571429	0.666667	0.9333
4	(Eggs)	(Milk)	0.428571	0.600000	0.8400
5	(Milk)	(Eggs)	0.428571	0.600000	0.8400
6	(Butter)	(Bread)	0.428571	1.000000	1.1667

สรุป: FP-Growth ให้ Association Rules เดียวกับ Apriori ทุกประการ แต่มีประสิทธิภาพดีกว่าบนชุดข้อมูลขนาดใหญ่ เนื่องจากสแกนฐานข้อมูลเพียงสองครั้งและไม่ต้องสร้าง Candidate Itemset

9.3.4 กรณีศึกษา – Online Retail

ดำเนินการ Market Basket Analysis บนข้อมูลจริงด้วยอัลกอริทึม Apriori และการ Mine Association Rule

9.3.4.1 การตั้งค่า

ติดตั้งไลบรารี mlxtend ซึ่งมี Apriori algorithm ที่มีประสิทธิภาพ:

```
!pip install mlxtend
```

9.3.4.2 โหลดชุดข้อมูล

ใช้ชุดข้อมูล Market Basket Analysis Data อัปโหลดไฟล์ .csv ไปยัง Google Colab และอย่าลืมตั้งค่า `index_col = 0` เมื่อใช้ `pd.read_csv()`:

```
import pandas as pd
from mlxtend.preprocessing import TransactionEncoder

df = pd.read_csv('/content/basket_analysis.csv',
index_col=0)
print(df.info())
df[:10]
```

ผลลัพธ์: DataFrame 999 แถว x 16 คอลัมน์ ประกอบด้วยสินค้า 16 ประเภท ได้แก่ Apple, Bread, Butter, Cheese, Corn, Dill, Eggs, Ice cream, Kidney Beans, Milk, Nutmeg, Onion, Sugar, Unicorn, Yogurt และ chocolate ทุกคอลัมน์เป็นชนิด bool (True/False)

9.3.4.3 ค้นหา Frequent Itemset ด้วย Apriori

ใช้ Apriori algorithm เพื่อ Mine Frequent Itemset จากชุดข้อมูล Online Retail:

```
from mlxtend.frequent_patterns import apriori

min_support = 0.2
frequent_itemsets = apriori(df,
min_support=min_support, use_colnames=True)
print('Frequent Itemsets:')
print(frequent_itemsets)
```

ผลลัพธ์ Frequent Itemsets (support >= 0.2) จำนวน 21 ชุด:

```
support itemsets
0 0.383383 (Apple)
1 0.384384 (Bread)
2 0.420420 (Butter)
3 0.404404 (Cheese)
4 0.407407 (Corn)
5 0.398398 (Dill)
6 0.384384 (Eggs)
7 0.410410 (Ice cream)
8 0.408408 (Kidney Beans)
9 0.405405 (Milk)
10 0.401401 (Nutmeg)
11 0.403403 (Onion)
12 0.409409 (Sugar)
13 0.389389 (Unicorn)
14 0.420420 (Yogurt)
15 0.421421 (chocolate)
16 0.207207 (Butter, Ice cream)
17 0.202202 (Butter, Kidney Beans)
18 0.202202 (Butter, chocolate)
19 0.200200 (Cheese, Kidney Beans)
20 0.202202 (chocolate, Ice cream)
21 0.211211 (Milk, chocolate)
```

9.3.4.4 สร้าง Association Rules

ใช้ Frequent Itemset สร้าง Association Rules และคำนวณเมตริก Confidence, Lift และ Support:

```
from      mlxtend.frequent_patterns      import
association_rules

min_confidence = 0.5
association_rules_df =
association_rules(frequent_itemsets,
```

```
metric='confidence',  
min_threshold=min_confidence)  
print('Association Rules:')  
print(association_rules_df)
```

ผลลัพธ์ Association Rules (confidence ≥ 0.5) จำนวน 3 Rules:

```
antecedents consequents support confidence lift  
0 (Ice cream) (Butter) 0.207207 0.504878 1.2009  
1 (Milk) (chocolate) 0.211211 0.520988 1.2363  
2 (chocolate) (Milk) 0.211211 0.501188 1.2363
```

9.3.4.5 ดีความผลลัพธ์

ผลลัพธ์คือ DataFrame ที่มี Association Rules พร้อมค่า Support, Confidence, Lift และเมตริกอื่นๆ สามารถตีความได้ดังนี้:

- Rule (Ice cream) $\rightarrow$ (Butter): Confidence = 0.505 หมายความว่า 50.5% ของลูกค้าที่ซื้อ Ice cream จะซื้อ Butter ด้วย, Lift = 1.201 แสดงความสัมพันธ์เชิงบวก
- Rule (Milk) $\rightarrow$ (chocolate): Confidence = 0.521 หมายความว่า 52.1% ของลูกค้าที่ซื้อ Milk จะซื้อ chocolate ด้วย, Lift = 1.236 แสดงความสัมพันธ์ที่น่าสนใจ
- Rule (chocolate) $\rightarrow$ (Milk): Confidence = 0.501 แสดงความสัมพันธ์สองทิศทาง — Milk และ chocolate มักถูกซื้อร่วมกัน

กรณีศึกษานี้แสดงวิธีดำเนินการ Association Rule Mining ด้วย Apriori algorithm บนชุดข้อมูล Groceries จริง อัลกอริทึม Apriori เป็นเทคนิคที่มีประสิทธิภาพสำหรับค้นหา Frequent Itemset และสร้าง Association Rules ใช้กันอย่างแพร่หลายในการวิเคราะห์ Market Basket และ Recommendation System สามารถปรับ Support และ Confidence ตามความต้องการเพื่อค้นพบ Rule ที่มากขึ้นหรือน้อยลง